



PERBANDINGAN PERFORMA DAN EFISIENSI YOLOV8 DAN YOLOV9 DALAM DETEKSI PENYAKIT DAUN TOMAT

Dody Adi Sancoko, Raka Aditya Waluya, Gede Bagus Krishnanditya Merta^{*)}

Program Studi Informatika, Telkom University, Indonesia

Abstrak: Deteksi dini penyakit daun tomat sangat penting untuk menjaga kualitas dan produktivitas pertanian. Penelitian ini bertujuan untuk membandingkan dua algoritma pembelajaran mendalam, yaitu You Only Look Once versi 8 (YOLOv8) dan versi 9 (YOLOv9), dalam mengevaluasi performa dan efisiensi deteksi terhadap sepuluh jenis penyakit daun tomat menggunakan dataset dari lingkungan alami. Sebanyak 10.825 citra dilakukan proses augmentasi dan *pre-processing*, meliputi rotasi, *zoom*, serta penyesuaian pencahayaan dan saturasi, hingga menghasilkan 15.154 citra untuk pelatihan. Hasil evaluasi menunjukkan bahwa kedua model mampu mencapai akurasi deteksi yang tinggi. Namun, YOLOv9 memiliki keunggulan dalam stabilitas pelatihan dan performa deteksi, terutama pada metrik ketepatan rata-rata (mean Average Precision) pada ambang batas 0,5 dan rentang 0,5 hingga 0,95. Di sisi lain, YOLOv8 menunjukkan efisiensi waktu pelatihan yang lebih baik, dengan durasi hanya sekitar setengah dari waktu yang dibutuhkan YOLOv9 untuk menyelesaikan 30 epoch. Oleh karena itu, pemilihan model tergantung pada apa yang ingin dicapai: jika fokus utama adalah akurasi deteksi, YOLOv9 lebih unggul, sementara jika yang lebih diutamakan adalah efisiensi waktu dan sumber daya, YOLOv8 menjadi pilihan yang lebih tepat.

Kata kunci: deep learning, deteksi penyakit daun tomat, YOLOv8, YOLOv9

I. PENDAHULUAN

Tomat (*Solanum lycopersicum*) merupakan salah satu komoditas pertanian yang sangat penting di Indonesia. Berdasarkan data dari *Food and Agriculture Organization* (FAO), Indonesia tercatat berhasil memanen 1.168.174 ton tomat pada tahun 2022, menjadikannya sebagai penghasil tomat terbesar di Asia Tenggara (*World Food and Agriculture – Statistical Yearbook 2024*, 2024). Produksi yang tinggi ini menunjukkan potensi besar tomat sebagai sumber pangan dan perekonomian yang vital bagi negara.

Meskipun Indonesia memiliki angka produksi tomat yang signifikan, tanaman tomat tetap rentan terhadap ancaman infeksi bakteri dan virus yang dapat memengaruhi kualitas dan hasil pertanian secara serius (Trivedi dkk., 2021). Salah satu gejala utama dari penyakit pada tomat biasanya muncul di permukaan daun, yang seringkali menjadi indikasi pertama dari adanya infeksi. Jika tidak diidentifikasi sejak dini, penyakit ini dapat menyebar dengan cepat dan menyebabkan kerugian yang signifikan baik dari segi kualitas maupun kuantitas hasil panen (Cordon dkk., 2022).

Identifikasi penyakit daun tomat dengan metode tradisional, seperti pengamatan langsung, terbukti kurang akurat dan sulit diterapkan dalam skala besar karena

^{*)} dodysancoko@student.telkomuniversity.ac.id

memerlukan biaya tinggi dan waktu yang lama (Islam dkk., 2024). Untuk mengatasi kendala ini, teknologi *machine learning*, khususnya *deep learning*, menawarkan solusi yang lebih efisien dengan kemampuan untuk mendeteksi penyakit secara otomatis. *Deep learning*, yang merupakan cabang dari *machine learning*, dapat mengekstraksi pola kompleks dari data berdimensi tinggi seperti gambar dan video menggunakan banyak lapisan jaringan syaraf tiruan (M. Li dkk., 2023). Keunggulannya terletak pada kemampuannya untuk memproses data besar tanpa memerlukan ekstraksi fitur manual, serta memberikan akurasi yang jauh lebih tinggi dibandingkan metode konvensional (Shen dkk., 2017). Dengan potensi tersebut, *deep learning* dapat mempercepat dan meningkatkan akurasi deteksi penyakit pada daun tomat, yang sangat penting untuk mencegah kerugian dalam produksi pertanian.

Algoritma *deep learning* yang umum digunakan saat ini antara lain YOLO (*You Look Only Once*) (Abulizi dkk., 2025), Faster R-CNN (Ren dkk., 2017), dan SSD (*Single Shot MultiBox Detection*) (W. Liu dkk., 2016). Para peneliti kemudian melakukan sejumlah studi terkait deteksi penyakit pada daun tomat menggunakan beberapa algoritma tersebut. Zayani et al. membangun membangun model berbasis YOLOv8 untuk deteksi penyakit tomat di dalam rumah kaca, yang mencapai akurasi 66,7% (Zayani dkk., 2024). Selain itu, Umar et al. mencoba mengintegrasikan *Simple Parament-Free Attention Module* (SimAM), *Dual Attention-in-Attention Module* (DAiAM), dan struktur *Max Pooling Convolution* (MPConv) ke dalam arsitektur YOLOv7 untuk mengurangi bobotnya sekaligus meningkatkan akurasi (Umar dkk., 2024). Namun, penelitian di atas dilakukan di dalam rumah kaca, bukan di lingkungan alami yang sebenarnya. Variasi cahaya dan warna daun,

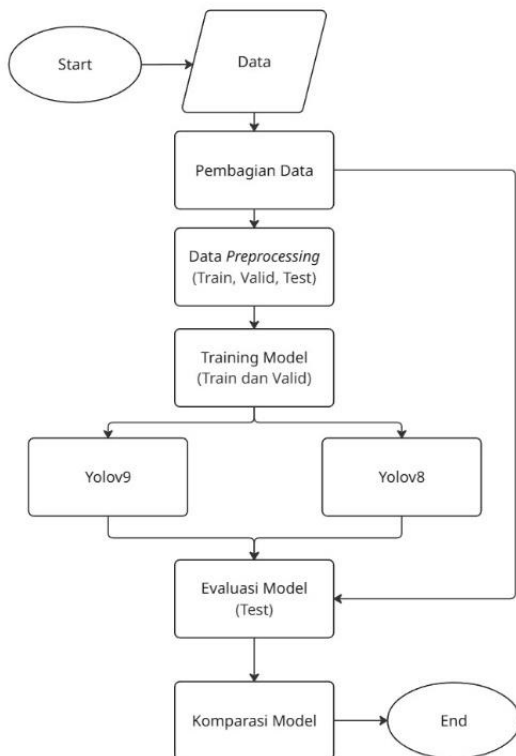
serta tumpang tindih penyakit menjadi tantangan yang sesungguhnya dalam deteksi penyakit daun tomat.

Untuk mengatasi tantangan tersebut, beberapa peneliti telah mengusulkan metode untuk mengatasinya. Pertama, (Roy dkk., 2022) mengusulkan *real time fine-grained* berperforma tinggi berdasarkan YOLOv4, sehingga masalah seperti kepadatan, bentuk tidak teratur, dan kesamaan tekstur dalam deteksi penyakit tanaman bisa teratasi. Dalam hal deteksi dini penyakit tomat, Liu dan Wang menggabungkan MobileNetv2 dengan YOLOv3 yang menghasilkan mAP sebesar 91,32% (J. Liu & Wang, 2021). Selain itu, Wang et al. mengusulkan metode deteksi penyakit tomat yang menggabungkan *Convolutional Block Attention Module* (CBAM) dan *multiscale reparameterized generalized feature fusion* (BiRepGFPN) berdasarkan YOLOv6 yang menghasilkan mAP sebesar 93,8% (Y. Wang dkk., 2024).

Meskipun studi-studi di atas telah menunjukkan hasil yang baik, mengidentifikasi kelas-kelas penyakit secara akurat di lingkungan alami masih menjadi tantangan. Deteksi yang salah masih sering terjadi yang disebabkan oleh faktor-faktor seperti bayangan yang mudah tertukar dengan bercak-bercak penyakit daun tomat. Untuk mengatasi masalah itu, penulis mengajukan metode yang lebih handal dalam menangani deteksi penyakit daun tomat. Metode YOLO secara luas sudah digunakan dalam bidang deteksi penyakit karena memiliki akurasi dan kecepatan yang seimbang, di antaranya yaitu YOLOv8 dan YOLOv9. Berbekal akurasinya yang tinggi dengan ukurannya yang ringan, YOLOv8 mampu mengatasi masalah deteksi penyakit daun tomat (Ye dkk., 2024). Berbeda dengan pendahulunya, YOLOv9 memperkenalkan struktur *neck* yang lebih

efisien dan menggabungkan *Efficient Layer Aggregation Network* (ELAN atau GELAN) untuk meningkatkan akurasi dan efisiensinya (Lu & Wang, 2024). Oleh karena itu, penelitian ini akan membandingkan performa dan efisiensi YOLOv8 dengan YOLOv9 dalam melakukan deteksi penyakit daun tomat pada lingkungan alami.

II. METODOLOGI



Gambar 1. Alur Penelitian

Gambar 1 menunjukkan alur penelitian yang diawali dengan persiapan dan pembagian dataset menjadi data *training*, *validation*, dan *testing*, yang kemudian digunakan untuk melatih, mengevaluasi dan pada akhirnya

membandingkan performa antara model YOLOv8 dan YOLOv9.

2.1. Pengumpulan Dataset

Dataset yang digunakan dalam penelitian ini berasal dari kumpulan data penyakit daun tomat yang dapat diakses secara publik pada platform Kaggle, data yang dikumpulkan dari internet, dan foto yang diambil oleh para peneliti sendiri. *Dataset* ini terdiri atas sepuluh kelas penyakit pada daun tomat, yaitu *tomato bacterial spot*, *tomato early blight*, *tomato late blight*, *tomato leaf mold*, *tomato septoria leaf spot*, *tomato spider mites (two-spotted spider mite)*, *tomato target spot*, *tomato yellow leaf curl virus*, *tomato healthy*, dan *tomato mosaic virus*. Dapat dilihat pada Gambar 2 bahwa *dataset* ini dikumpulkan dari berbagai lingkungan alami, sehingga menghasilkan dataset yang bervariasi dari segi pencahayaan, tumpang tindih, dan warna daun



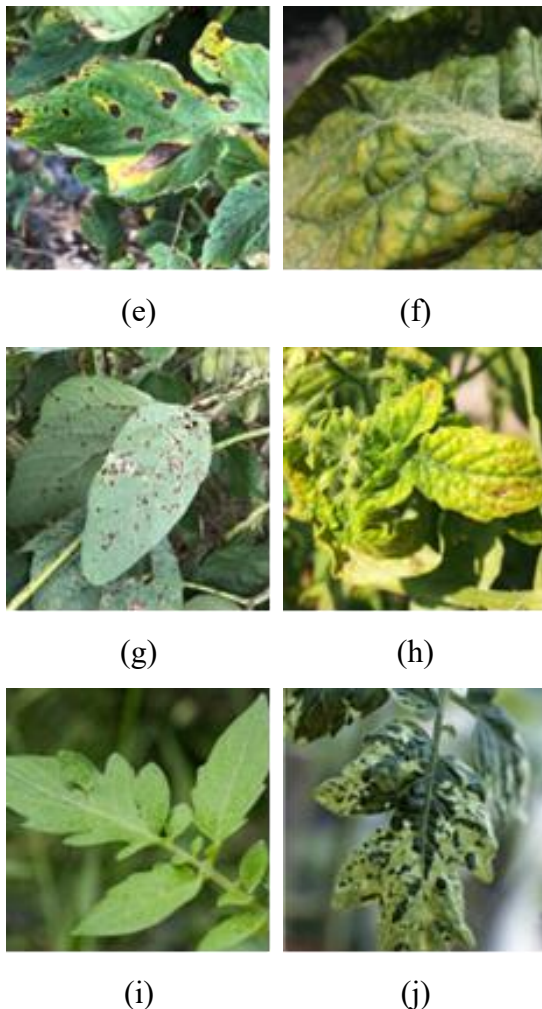
(a)

(b)



(c)

(d)



Gambar 2. (a) Bactetial Spot, (b) Early Blight, (c) Late Blight, (d) Leaf Mold, (e) Septoria Leaf Spot, (f) Spide Mites, (g) Target Spot, (h) Yellow Leaf Curl Virus, (i) Healthy, (j) Mosaic Virus

2.2. Pre-processing dan Splitting Data

Pre-processing gambar melibatkan beberapa teknik untuk meningkatkan kualitas dataset sebelum dilatih dengan model. Semua gambar diberi anotasi *bounding box* dengan menggunakan Roboflow. Kemudian, *dataset* yang berjumlah 10.825 gambar ini akan dibagi 70% sebagai data pelatihan, 20% sebagai

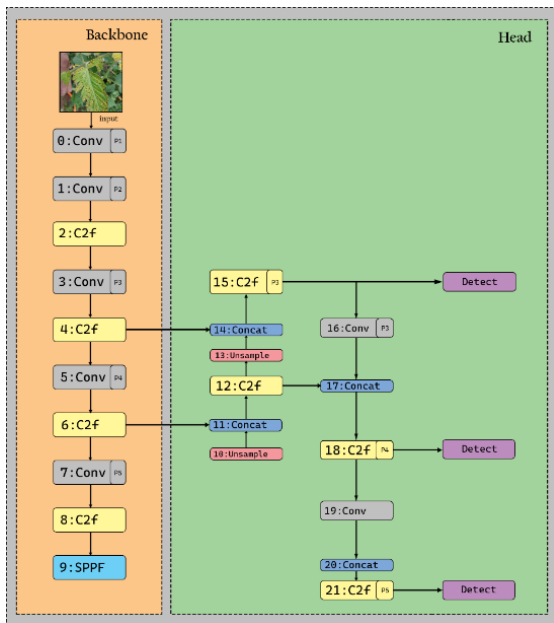
data validasi, dan 10% sebagai data uji. Augmentasi dilakukan pada dataset ini untuk membantu membangun gambar baru yang serupa dengan membalik secara horizontal, rotasi acak sebesar $\pm 15^\circ$, dan *zoom* acak dalam rentang 0.9-1.1. Selain itu, dilakukan pula penyesuaian pencahayaan sebesar $\pm 15\%$ dan penyesuaian saturasi sebesar $\pm 25\%$. Setelah proses augmentasi dilakukan, data pelatihan bertambah menjadi 15.154. Terakhir, ukuran gambar disamaratakan menjadi 640×640 piksel

2.3. Algoritma YOLOv8

YOLOv8 merupakan model serbaguna yang mendukung berbagai tugas *computer vision* mulai dari deteksi objek, segmentasi hingga estimasi pose, pelacakan, dan klasifikasi (R. Li dkk., 2024). Fleksibilitas ini menjadikannya alat yang ampuh untuk beragam aplikasi analisis visual. YOLOv8 mengadopsi arsitektur dasar serupa YOLOv5, namun dengan modul C2f (cross-stage partial bottleneck dengan dua konvolusi) yang menyempurnakan integrasi fitur tingkat tinggi dan informasi kontekstual untuk akurasi deteksi lebih baik. Model ini menggunakan desain anchor-free dengan decoupled head yang memproses objectness, klasifikasi, dan regresi secara terpisah, sehingga meningkatkan presisi secara keseluruhan. Untuk output, YOLOv8 memanfaatkan fungsi sigmoid dan softmax untuk probabilitas objek dan kelas, serta mengandalkan fungsi loss CloU, DFL, dan binary cross-entropy untuk meningkatkan performa deteksi, khususnya pada objek berukuran kecil (Terven dkk., 2023).

YOLOv8s merupakan salah satu varian ringan dari YOLOv8 yang akan dilatih sebagai model deteksi penyakit daun tomat. Gambar 3 merupakan struktur jaringan dari YOLOv8s. Arsitektur jaringan YOLOv8s dimulai dengan tahap Input yang menyesuaikan ukuran data

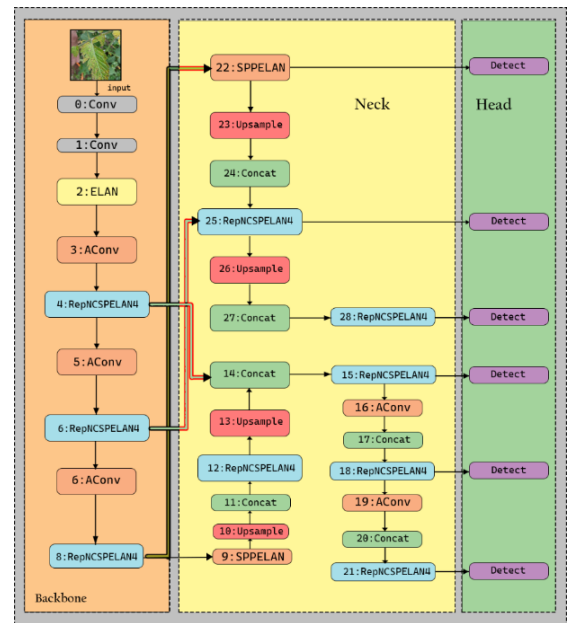
gambar agar sesuai untuk pelatihan model. Selanjutnya, *backbone*, yang menggunakan jaringan CSPDarkNet-53 sebagai kerangka utama, mengekstrak peta fitur (P1–P5) melalui lapisan konvolusional. *Receptive field* (area cakupan visual) pada peta fitur ini secara progresif meluas. Kemudian, bagian *neck* memperkenalkan struktur FPN (*Feature Pyramid Network*) dan PAN (*Path Aggregation Network*) yang canggih. FPN mendeteksi target beragam ukuran dengan menyalurkan fitur semantik dari atas ke bawah, sementara PAN sebagai piramida fitur dari bawah ke atas menangani fitur posisi yang kuat. Keduanya berkolaborasi untuk menggabungkan fitur dari berbagai lapisan backbone ke lapisan deteksi yang berbeda. Akhirnya, *prediction (head)* sebagai kepala model bertanggung jawab atas output prediksi akhir, seiring meningkatnya *receptive field* dari P3 hingga P5, target yang diprediksi bertransisi dari ukuran kecil, sedang, hingga besar (R. Li dkk., 2024).



Gambar 3. Arsitektur YOLOv8s.

2.4. Algoritma YOLOv9

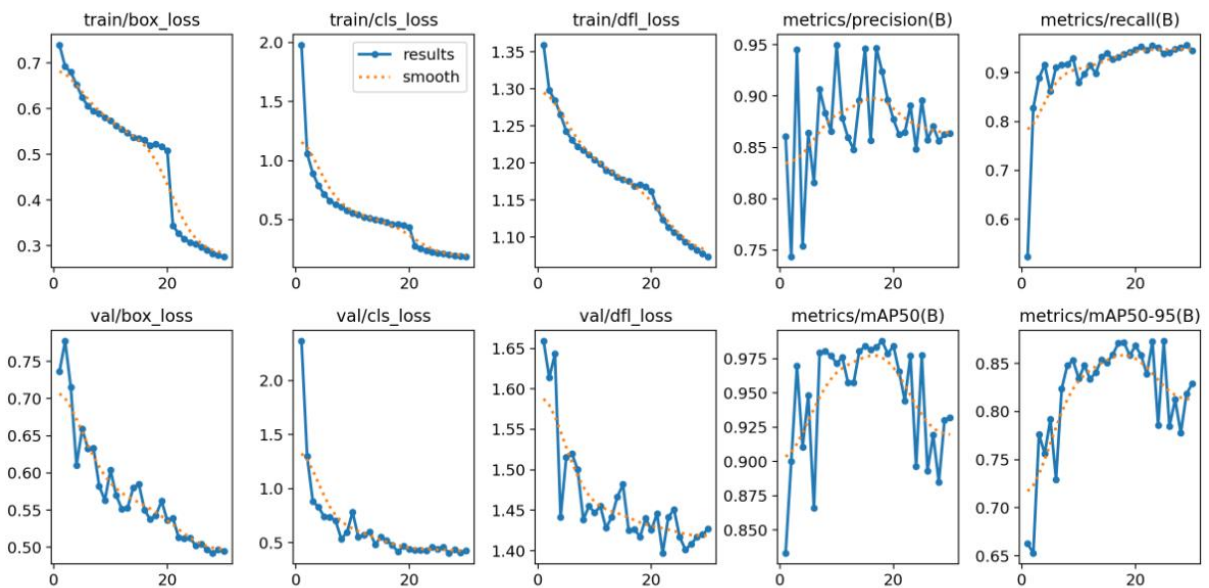
Model YOLOv9 mengadaptasi efisiensi deteksi objek dari seri YOLO sebelumnya, dengan menerapkan arsitektur jaringan yang lebih inovatif serta strategi pelatihan yang canggih, guna mengoptimalkan kinerjanya dalam berbagai tugas pengenalan gambar (C.-Y. Wang dkk., 2025). Untuk mengatasi keterbatasan model YOLO generasi sebelumnya yang cenderung kehilangan informasi penting selama proses ekstraksi fitur dan transformasi spasial, YOLOv9 memperkenalkan konsep *Programmable Gradient Information* (PGI), yang bertujuan memanfaatkan informasi gradien guna mendukung proses pelatihan dan pembelajaran jaringan. Selain itu, YOLOv9 merancang struktur jaringan ringan yang inovatif, yakni *General Efficient Layer Aggregation Network* (GELAN) untuk meningkatkan efisiensi dalam deteksi objek (An dkk., 2024).



Gambar 4. Arsitektur YOLOv9s.

Pada penelitian ini, kami memilih melatih model dengan menggunakan salah satu varian ringan dari YOLOv9, yaitu YOLOv9s. Gambar 4 menunjukkan struktur jaringan dari YOLOv9s yang merupakan salah satu varian dari seri YOLOv9 dan dirancang untuk memberikan deteksi dengan presisi tinggi, sekaligus meminimalkan penggunaan sumber daya komputasi dan meningkatkan efisiensi operasional. Conv merupakan operasi konvolusi, ELAN adalah modul *Efficient Layer Aggregation Network*, RepNCSPPELAN4 merupakan jaringan yang direparametrisasi dengan koneksi *Cross-Stage Partial* dan arsitektur *Efficient Layer Aggregation Network*. AConv adalah modul konvolusi penyederhanaan untuk proses *downsampling*,

SPPELAN merupakan modul *Spatial Pyramid Pooling* yang dilengkapi dengan jaringan atensi lokal yang ditingkatkan, *Upsample* adalah modul untuk proses *upsampling*, *Concat* berfungsi sebagai modul penggabungan fitur, dan *Detect* merupakan kepala deteksi (*detection head*) dalam jaringan. Pada model YOLOv9, RepNCSPPELAN4 berperan sebagai modul ekstraksi dan fusi fitur. Modul ini dirancang berdasarkan arsitektur GELAN dengan menggabungkan keunggulan struktur CSPNet dan ELAN untuk meningkatkan akurasi deteksi serta kemampuan model dalam mengenali objek berukuran kecil melalui penggabungan fitur multi-skala (Shi dkk., 2024).



Gambar 5. Visualisasi hasil *training* model YOLOv8

III. HASIL DAN PEMBAHASAN

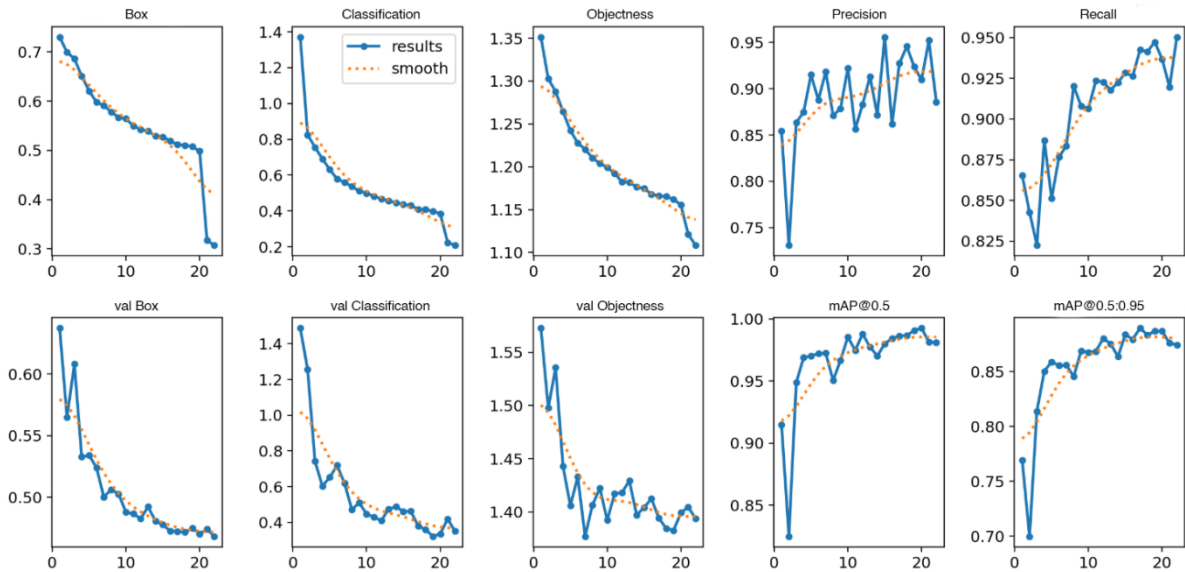
3.1. Hasil Training Model YOLOv8

Pada Gambar 5 proses pelatihan model YOLOv8 dilakukan dengan melalui serangkaian grafik metrik. Secara umum,

grafik ini menunjukkan proses pelatihan yang berhasil, ditandai oleh tren penurunan yang sehat dan konsisten pada semua kurva kerugian (*loss*) yaitu *box*, *classification*, dan *objectness* baik pada data latih (baris atas)

maupun data validasi (baris bawah). Tren penurunan ini mengindikasikan bahwa model belajar secara efektif untuk meminimalkan kesalahan dan mampu melakukan generalisasi pada data yang belum pernah dilihat sebelumnya. Di sisi lain, meskipun metrik performa seperti *recall*, $mAP@0.5$, dan $mAP@0.5:0.95$ menunjukkan tren kenaikan

yang diharapkan, kurva-kurva ini, terutama *precision* dan mAP , menampilkan volatilitas atau gejala yang cukup terlihat antar epoch. Hal ini menandakan bahwa meskipun model berhasil meningkatkan kinerjanya, proses pencapaian performa puncaknya diwarnai dengan sedikit ketidakstabilan.



Gambar 6. Visualisasi hasil *training* model YOLOv9

3.2. Hasil Training Model YOLOv9

Gambar 6 memberikan visualisasi grafik komprehensif dari proses pelatihan model YOLOv9, yang secara jelas menunjukkan sebuah sesi pelatihan yang sangat berhasil dan stabil. Seluruh kurva kerugian (*loss*) termasuk *box*, *classification*, dan *objectness* untuk data latih dan validasi menampilkan tren penurunan yang sangat mulus dan konsisten, mengindikasikan bahwa model belajar dengan efisien dan memiliki kemampuan generalisasi yang kuat. Karakteristik yang paling menonjol adalah stabilitas pada grafik performa metrik validasi kunci seperti $mAP@0.5$ dan

$mAP@0.5:0.95$ menunjukkan peningkatan yang progresif dan stabil menuju konvergensi, tanpa adanya fluktuasi atau gejala signifikan yang sering terlihat pada proses pelatihan. Secara keseluruhan, grafik-grafik ini menggambarkan sebuah proses pelatihan yang tidak hanya efektif dalam mencapai performa tinggi tetapi juga sangat kokoh dan efisien.

3.3. Hasil Komparasi Model

Tabel 1 merupakan hasil komparasi waktu *training* antar kedua model yang dibandingkan. Dalam hal efisiensi waktu, YOLOv8 jauh lebih unggul dibandingkan


dengan YOLOv9. Berdasarkan hasil komparasi waktu *training*, YOLOv8 memerlukan 77,11 menit untuk menyelesaikan 30 *epoch*, sementara YOLOv9 membutuhkan 175,83 menit, hampir dua kali lipat lebih lama. Keunggulan YOLOv8 dalam efisiensi ini sangat penting, terutama dalam penerapan di lapangan yang membutuhkan kecepatan dalam melatih model dengan sumber daya terbatas. Meskipun YOLOv9 memiliki performa akurasi yang lebih baik, kecepatan *training* yang lebih tinggi pada YOLOv8 membuatnya lebih efisien dalam hal waktu dan sumber daya, yang dapat menjadi faktor penentu saat memilih model yang tepat untuk aplikasi praktis.

Tabel 1. Komparasi *training time*

Model	Training Time (menit)
YOLOv8	77,11
YOLOv9	175,83

Berdasarkan perbandingan kedua hasil evaluasi yang diperlihatkan pada Gambar 7, model YOLOv9 secara konsisten menunjukkan performa yang lebih unggul dibandingkan YOLOv8 di seluruh metrik yang diukur. Keunggulan paling signifikan terlihat pada metrik *precision* (0.9274 pada YOLOv9 dan 0.8956 pada YOLOv8) serta *F1-score* (0.9281 dan 0.8983), yang menunjukkan bahwa YOLOv9 memiliki tingkat akurasi dan keseimbangan antara *precision* dan *recall* yang lebih baik. Meskipun pada metrik *recall* dan *mAP@0.5* perbedaannya lebih tipis, YOLOv9 tetap memimpin. Kinerja superior ini juga terkonfirmasi pada metrik *mAP@0.5:0.95* (0.8897 dan 0.8732), yang mengindikasikan bahwa YOLOv9 tidak hanya lebih baik dalam mendeteksi objek, tetapi juga lebih presisi dalam menentukan lokasi *bounding box*

sesuai standar *Intersection over Union* (IoU) yang lebih ketat.



Gambar 7. Komparasi evaluasi model

IV. KESIMPULAN

Penelitian ini membandingkan performa dan efisiensi dua model deep learning terkini, yaitu YOLOv8 dan YOLOv9, dalam mendeteksi sepuluh jenis penyakit daun tomat berbasis citra dari lingkungan alami. Hasil evaluasi menunjukkan bahwa keduanya mampu mencapai akurasi deteksi yang tinggi, namun dengan karakteristik keunggulan yang berbeda. YOLOv9 menunjukkan performa terbaik dengan stabilitas pelatihan yang konsisten serta nilai *mAP@0.5* sebesar 0,921 dan *mAP@0.5:0.95* sebesar 0,8897, disertai nilai *F1-score* tertinggi sebesar 0,9281, menjadikannya pilihan ideal untuk aplikasi yang membutuhkan presisi tinggi dalam kondisi visual yang kompleks. Sementara itu, YOLOv8 unggul dalam efisiensi waktu pelatihan, menyelesaikan 30 *epoch* dalam waktu yang jauh lebih singkat, sehingga lebih cocok diterapkan pada sistem dengan keterbatasan sumber daya komputasi. Oleh karena itu, pemilihan antara kedua model bergantung pada kebutuhan spesifik: YOLOv9

lebih tepat untuk akurasi maksimum, sedangkan YOLOv8 menjadi alternatif optimal untuk efisiensi waktu dan sumber daya.

DAFTAR PUSTAKA

- Abulizi, A., Ye, J., Abudukelimu, H., & Guo, W. (2025). DM-YOLO: Improved YOLOv9 model for tomato leaf disease detection. *Frontiers in Plant Science*, 15, 1473928. <https://doi.org/10.3389/fpls.2024.1473928>
- An, R., Zhang, X., Sun, M., & Wang, G. (2024). GC-YOLOv9: Innovative smart city traffic monitoring solution. *Alexandria Engineering Journal*, 106, 277–287. <https://doi.org/10.1016/j.aej.2024.07.004>
- Cordon, G., Andrade, C., Barbara, L., & María Romero, A. (2022). Early detection of tomato bacterial canker by reflectance indices. *Information Processing in Agriculture*, 9(2), 184–194. <https://doi.org/10.1016/j.inpa.2021.06.004>
- Islam, S. U., Zaib, S., Ferraioli, G., Pascazio, V., Schirinzi, G., & Husnain, G. (2024). Enhanced Deep Learning Architecture for Rapid and Accurate Tomato Plant Disease Diagnosis. *AgriEngineering*, 6(1), 375–395. <https://doi.org/10.3390/agriengineering6010023>
- Li, M., Jiang, Y., Zhang, Y., & Zhu, H. (2023). Medical image analysis using deep learning algorithms. *Frontiers in Public Health*, 11, 1273253. <https://doi.org/10.3389/fpubh.2023.1273253>
- Li, R., Li, Y., Qin, W., Abbas, A., Li, S., Ji, R., Wu, Y., He, Y., & Yang, J. (2024). Lightweight Network for Corn Leaf Disease Identification Based on Improved YOLO v8s. *Agriculture*, 14(2), 220. <https://doi.org/10.3390/agriculture14020220>
- Liu, J., & Wang, X. (2021). Correction to: Early recognition of tomato gray leaf spot disease based on MobileNetv2-YOLOv3 model. *Plant Methods*, 17(1), 19. <https://doi.org/10.1186/s13007-021-00708-7>
- Liu, W., Anguelov, D., Erhan, D., Szegedy, C., Reed, S., Fu, C.-Y., & Berg, A. C. (2016). SSD: Single Shot MultiBox Detector. Dalam B. Leibe, J. Matas, N. Sebe, & M. Welling (Ed.), *Computer Vision – ECCV 2016* (Vol. 9905, hlm. 21–37). Springer International Publishing. https://doi.org/10.1007/978-3-319-46448-0_2
- Lu, D., & Wang, Y. (2024). MAR-YOLOv9: A multi-dataset object detection method for agricultural fields based on YOLOv9. *PLOS ONE*, 19(10), e0307643. <https://doi.org/10.1371/journal.pone.0307643>
- Ren, S., He, K., Girshick, R., & Sun, J. (2017). Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(6), 1137–1149. <https://doi.org/10.1109/TPAMI.2016.2577031>
- Roy, A. M., Bose, R., & Bhaduri, J. (2022). A fast accurate fine-grain object detection model based on YOLOv4 deep neural network. *Neural Computing and*

- Applications*, 34(5), 3895–3921.
<https://doi.org/10.1007/s00521-021-06651-x>
- Shen, D., Wu, G., & Suk, H.-I. (2017). Deep Learning in Medical Image Analysis. *Annual Review of Biomedical Engineering*, 19(1), 221–248.
<https://doi.org/10.1146/annurev-bioeng-071516-044442>
- Shi, Y., Duan, Z., Qing, S., Zhao, L., Wang, F., & Yuwen, X. (2024). YOLOv9s-Pear: A Lightweight YOLOv9s-Based Improved Model for Young Red Pear Small-Target Recognition. *Agronomy*, 14(9), 2086.
<https://doi.org/10.3390/agronomy14092086>
- Terven, J., Córdova-Esparza, D.-M., & Romero-González, J.-A. (2023). A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS. *Machine Learning and Knowledge Extraction*, 5(4), 1680–1716.
<https://doi.org/10.3390/make5040083>
- Trivedi, N. K., Gautam, V., Anand, A., Aljahdali, H. M., Villar, S. G., Anand, D., Goyal, N., & Kadry, S. (2021). Early Detection and Classification of Tomato Leaf Disease Using High-Performance Deep Neural Network. *Sensors*, 21(23), 7987.
<https://doi.org/10.3390/s21237987>
- Umar, M., Altaf, S., Ahmad, S., Mahmoud, H., Mohamed, A. S. N., & Ayub, R. (2024). Precision Agriculture Through Deep Learning: Tomato Plant Multiple Diseases Recognition With CNN and Improved YOLOv7. *IEEE Access*, 12, 49167–49183.
<https://doi.org/10.1109/ACCESS.2024.3383154>
- Wang, C.-Y., Yeh, I.-H., & Mark Liao, H.-Y. (2025). YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information. Dalam A. Leonardis, E. Ricci, S. Roth, O. Russakovsky, T. Sattler, & G. Varol (Ed.), *Computer Vision – ECCV 2024* (Vol. 15089, hlm. 1–21). Springer Nature Switzerland.
https://doi.org/10.1007/978-3-031-72751-1_1
- Wang, Y., Zhang, P., & Tian, S. (2024). Tomato leaf disease detection based on attention mechanism and multi-scale feature fusion. *Frontiers in Plant Science*, 15, 1382802.
<https://doi.org/10.3389/fpls.2024.1382802>
- World Food and Agriculture – Statistical Yearbook 2024*. (2024). FAO.
<https://doi.org/10.4060/cd2971en>
- Ye, R., Shao, G., He, Y., Gao, Q., & Li, T. (2024). YOLOv8-RMDA: Lightweight YOLOv8 Network for Early Detection of Small Target Diseases in Tea. *Sensors*, 24(9), 2896.
<https://doi.org/10.3390/s24092896>
- Zayani, H. M., Ammar, I., Ghodhbani, R., Maqbool, A., Saidani, T., Slimane, J. B., Kachoukh, A., Kouki, M., Kallel, M., Alsuwaylimi, A. A., & Alenezi, S. M. (2024). Deep Learning for Tomato Disease Detection with YOLOv8. *Engineering, Technology & Applied Science Research*, 14(2), 13584–13591.
<https://doi.org/10.48084/etasr.7064>